Comandos y resultados verificados

Comandos locales de verificación, demostración y laboratorio medidos en `/Users/jose/Documents/the-power/3-rag` sin llamadas de pago.

1. Diagnóstico, calidad de código y batería de tests

Comando	Código	Resultado verificado
`bun run check`	`0`	Formato (`vp fmt`), lint con tipos y comprobación estricta de TypeScript en `apps/`, `packages/`, `scripts/` y `lab/`.
`bun run test`	`0`	Batería completa de pruebas unitarias y de grafos en verde (incluidos los validadores de escala `[0, 1]`, los nodos separados `rank` y `assess` y el laboratorio `pgvector` de 768 dimensiones).
`bun run preflight`	`0`	`APP_MODE efectivo: demo`, sin RAG `offline-demo`, RAG y CRAG `offline-fixture`.
`bun run build`	`0`	Compila el frontend React y el bundle del Worker de Cloudflare sin errores.

2. Comandos del laboratorio reproducible S10 y S11 (`lab/`)

Comando	Código	Qué ejecuta y qué imprime
`bun run lab:real eval --execute --max-spend-usd 5`	`0`	**Ejecución real del 24/10/2026 sobre ThePower Shop** (12 políticas, 54 fragmentos): RAG `14/14` y `6/6`, CRAG `14/14` y `6/6`, `1,00` frente a `1,60` búsquedas medias, mediana `3,2 s` frente a `8,9 s` en respondibles. Recibos en `docs/evidence/thepower-shop-2026-10-24/`.
`bun run lab:rebuild`	`0`	(Medición anterior al 24/10, con AetherCloud.) Vacía el índice y lo reconstruye desde los **10 documentos ficticios de AetherCloud** (`lab/corpus/sources/`): versión `lab-689164ca81cd`, `10` documentos, `20` fragmentos (`900/80`), `768` dimensiones e índice HNSW `lab_chunks_embedding_hnsw_idx (vector_cosine_ops)`.
`bun run lab:demo`	`0`	Ejecuta 5 casos: 1) S10 respuesta con cita `04-almacenamiento-y-cifrado-kms:00`; 2) S10 rechazo previo sobre Windows Server (`gen=false`); 3) S11 CRAG suficiente tras `rerank` sobre `top-10`; 4) S11 CRAG parcial con 2 búsquedas y 1 reformulación (`retrieve->rerank->assess->retain->reformulate->retrieve->rerank->assess->answer`); 5) S11 CRAG agotando 3 búsquedas y 2 reformulaciones (`gen=false`).
`bun run lab:eval`	`0`	Ejecuta las **20 preguntas nuevas de test (14 respondibles + 6 sin respuesta)** en RAG básico y CRAG y escribe `lab/eval/resultados-laboratorio.md`: **RAG `16/20` (`10/14` respondibles, `6/6` rechazos, `1,00` búsquedas medias)** frente a **CRAG `17/20` (`11/14` respondibles, `6/6` rechazos, `1,80` búsquedas medias)**.

3. Comandos del demostrador web en modo `demo` (`bun run dev`)

Con `bun run dev` levantado en `http://localhost:5173/`:

Etapa y caso	Audiencia	Resultado en el demostrador local
Sin RAG · *«¿Cómo modela LangGraph un agente con estado y nodos?»*	`program`	Stream `offline-demo` sin fuentes; uso y coste `no medido`.
RAG básico · *«¿Cuándo es la clase de RAG?»*	`program`	`clarify`: pide elegir el grupo `L/X` o `M/J` sin buscar ni llamar al modelo.
RAG básico · *«¿Cuándo es la clase de RAG S10?»*	`M/J`	Cita `c3a59a406888b:calendario-mj:10` y devuelve `2026-10-22`.
RAG básico · *«¿Qué beca interna del año 1991 cubre este programa?»*	`program`	`refuse`: no supera el umbral y rechaza sin llamar al modelo.
CRAG · `sufficient-s5`	`program`	1 búsqueda, pasos `retrieve → rank → assess → answer`, cita `s05-langgraph:00`.
CRAG · `partial-s5-s6`	`program`	2 búsquedas, 1 reformulación, conserva S5 (`0,800`), une S6 (`0,860`) sin duplicar y responde con ambas citas.
CRAG · `irrelevant-then-s6`	`program`	2 búsquedas, 1 reformulación, descarta S16 (`0,200`) en el intento 1 y responde solo con S6 (`0,880`).
CRAG · `missing-info` (beca de 1991)	`program`	3 búsquedas, 2 reformulaciones, generación `0` y final `refuse`.
CRAG · `evaluator-error`	`program`	Salida inválida detectada por `validateRanking` / `validateAssessment`; termina en `error` sin reintentos.