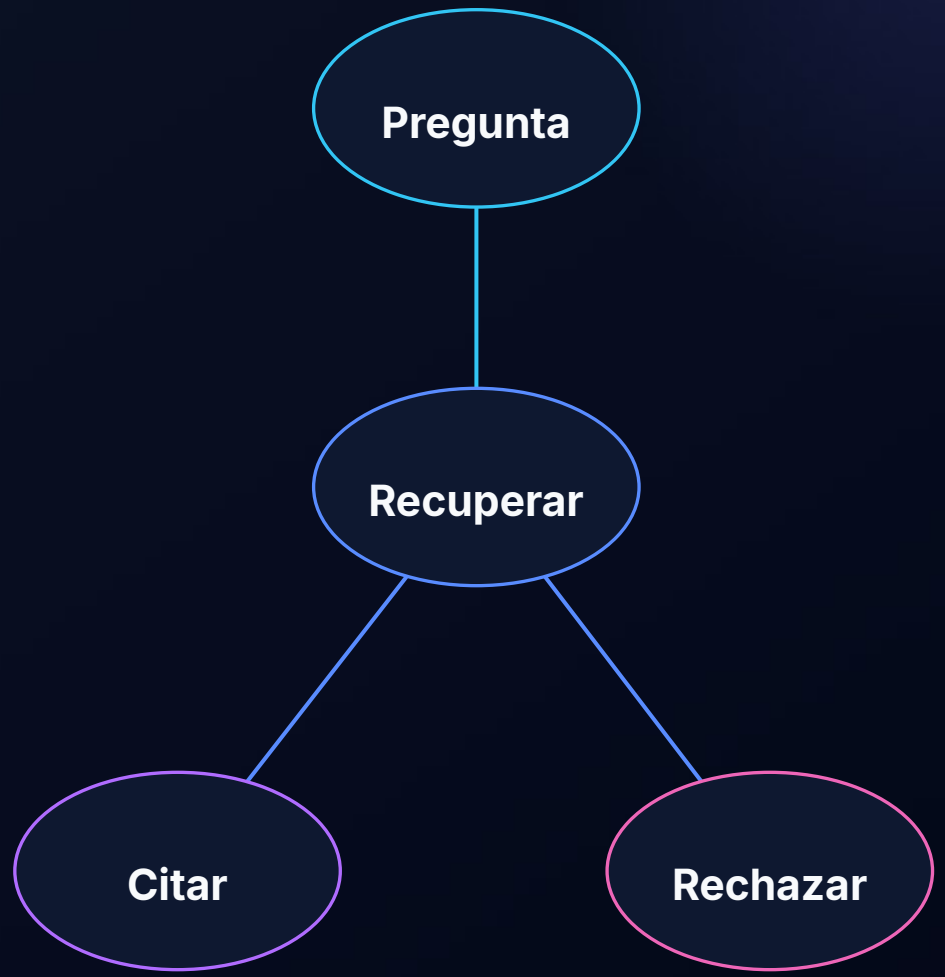
RAG básico
Asistente del curso

Recorrido semántico, umbral previo y citas verificables. Demostrador del curso y laboratorio pgvector reproducible.

22 octubre 2026 · 18:30–20:00

Semántico · BGE-M3 1024 / pgvector 768



thePower · AI Engineer

José Antonio Nuevo

Antes de empezar

El QR de AI Engineer evalúa la clase anterior: S9.

Tu feedback

Escanea el QR. Valora la clase del 20 de octubre.

Hoy veremos

Fragmentación, embeddings, índice HNSW, umbral y citas.



Evaluación de la clase anterior

La misma pregunta, sin documentos

Abstenerse o ser genérico es válido. No forzamos una alucinación.

Sin fuentes

Este modo no recupera fichas del curso.

Qué aparece

El modelo responde sin fuentes y desconoce fechas internas.

Qué señalar

Sin citas; uso o coste desconocidos viajan como null.

Corpus y perfiles del sistema

S1–S20 en el demostrador y 10 documentos ficticios en lab/.

Pieza	Identidad	Estado verificado
Corpus curso	c3a59a406888b	22 docs, 69 fragmentos
Índice real	p76509a5f9743	BGE-M3 1024 d, coseno 0,50
Lab pgvector	lab-689164ca81cd	10 docs, vector(768) + HNSW

Ambos reconstruibles desde Markdown en bruto e índice vacío.

Fragmentación y solapamiento

Trocear por secciones y párrafos sin cortar un dato a mitad.

Tamaño y solape

900 caracteres y 80 de solapamiento entre fragmentos.

Sección e ID

Conserva el encabezado H2 y crea un ID determinista.

```
chunkMarkdown(body, {
  maxChars: 900,
  overlapChars: 80,
});
// Conserva sección ##
// y solapa 80 chars
// ID: version:doc:00
// packages/rag/src/chunk.ts
```

El solapamiento evita perder cifras o condiciones entre cortes.

Embeddings e índice vectorial

Mismo modelo y dimensión al ingerir documentos y al consultar.

```
embedding vector(768) NOT NULL
USING hnsw (embedding
  vector_cosine_ops)
WITH (m = 16, ef_construction = 64)
```



Lab: vector(768) + HNSW · Curso: BGE-M3 1024 d

En pgvector ⟺, menor distancia = más próximo

Consultar, filtrar y puntuar

Filtro en la consulta vectorial y selección por umbral previo.



El filtro de grupo se aplica en la consulta, no solo en el prompt.

Calibración del umbral y rechazo

Se calibra con validación separada del test; corta antes de generar.

```
sim ⩾ 0.50 // BGE-M3 1024d
dist ⩽ 0.75 // pgvector 768d
```



Un prompt de «si no sabes, dilo» no sustituye este control.

Construcción del contexto y citas

El texto recuperado es dato no fiable, nunca instrucción.

Bloque DATOS

Aísla los fragmentos frente a instrucciones incrustadas.

Generación

Redacta solo con los fragmentos que superaron el corte.

Cita [cite:id]

Se valida contra los IDs seleccionados antes de responder.

`Variante complete: solo cuando todo el corpus cabe en ventana.`

Si no consta, se dice

Falta de evidencia, cohorte o rechazo. No se inventa.

Aclarar

Sin cohorte, una fecha no se responde.

Rechazar

Sin contexto útil no hay llamada al modelo.

Cohortes

M/J y L/X no comparten la fecha de S10.

Reconstruir y evaluar con control

Desde documentos en bruto e índice vacío hasta el test 14 + 6.



Validación para calibrar; 20 preguntas reservadas para medir.

```
bun run lab:rebuild && bun run lab:eval
```

Ejercicio S10 y el paso a CRAG

8+ documentos ficticios y PostgreSQL con pgvector (vector(768) + HNSW).

Stack e índice

GEN_MODEL_ID, EMBEDDING_MODEL_ID, vector(768) e índice HNSW.

Reconstrucción

Desde archivos en bruto e índice vacío, con umbral y citas.

Evaluación 14+6

Ejecutar las 20 preguntas y presentar aciertos/14 y rechazos/6.

Dedicación orientativa: 4 a 6 horas. Laboratorio en lab/.

Consulta · Los tres perfiles del proyecto

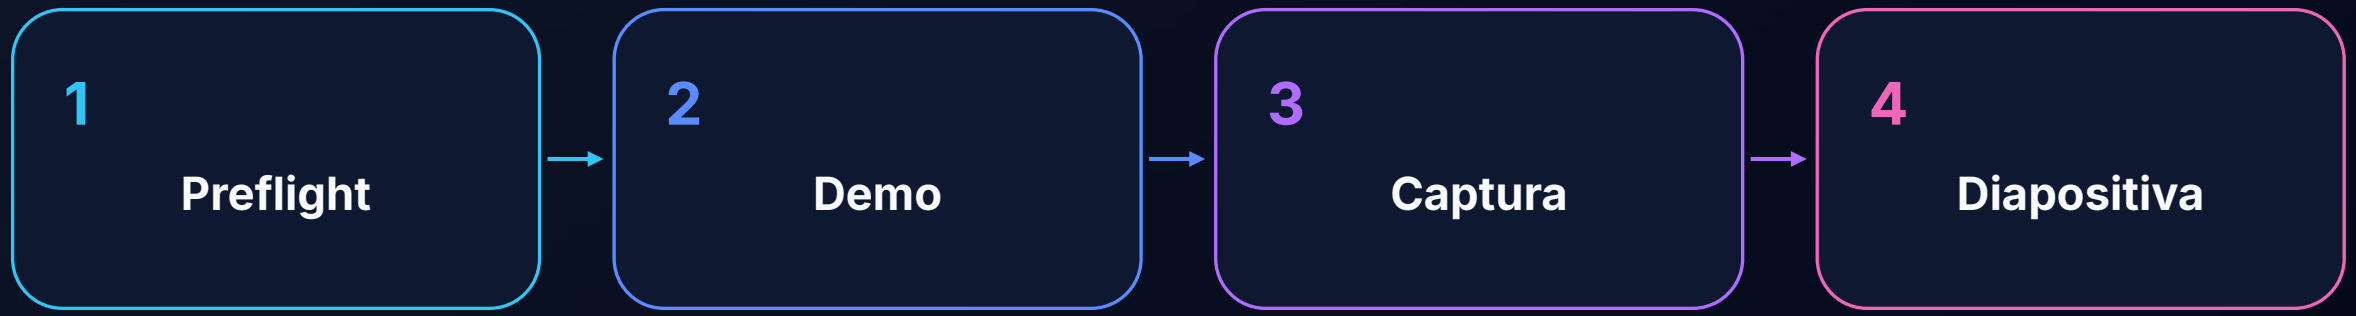
Recorrido semántico principal, laboratorio pgvector y respaldo demo.

Pieza	Curso (semántico)	Laboratorio (S10/S11)
Índice	Vectorize 1024 d (BGE-M3)	pgvector vector(768) + HNSW
Modelo	claude-haiku-5-5 (Anthropic)	GEN_MODEL_ID / EMBEDDING_MODEL_ID
Umbral	0,50 (variante: complete)	0,25 similitud (0,75 distancia ⇔)

En demo offline se usa fixture-token-hash-v1 (128 d, corte 0,33).

Consulta · Si algo falla

La clase sigue con capturas del 3 de octubre, modo demo.



No lances activate --execute. No hay alta autorizada.

```
bun run preflight && bun run dev
```

Para cerrar

El QR sigue siendo el de AI Engineer: evalúa S9, no esta clase.

Tu feedback

Si no se ha escaneado, este es el momento.

La próxima

S11, 27 de octubre: el mismo asistente, con CRAG.



Evaluación de la clase anterior