S10 · AI ENGINEER

RAG

Chatbot con documentación propia



José Antonio Nuevo
22 octubre 2026 · 18:30–20:00

30 conceptos / 50 práctica / 10 cierre

Feedback de S9 y objetivo de hoy

Escanea el QR de AI Engineer

Evalúa S9 · PostgreSQL y pgvector · 20 de octubre

Hoy: recuperar, fundamentar, citar y rechazar



Prompting, fine-tuning y RAG

Prompting: instrucciones y ejemplos por petición

Fine-tuning: comportamiento aprendido o adaptadores

RAG: documentos recuperados durante la consulta

Tres formas de aportar contexto

Contexto completo: todo el corpus autorizado si cabe

RAG selectivo: búsqueda, filtros y umbral

CRAG: evalúa suficiencia y corrige la búsqueda

El corpus delimita lo que se puede saber

Curso: 22 documentos, 69 fragmentos, dos grupos

Laboratorio: 10 documentos ficticios de AetherCloud

Solo datos ficticios; no completamos los huecos

Preparar una vez; consultar muchas veces

Preparación: leer, limpiar, fragmentar, embeber, guardar

Consulta: embeber pregunta, buscar, seleccionar, generar

El generador recibe texto y procedencia

Fragmentación con significado y procedencia

Limpieza sin perder cifras ni identificadores

900 caracteres como máximo y 80 de solapamiento

ID estable: versión, documento y ordinal

Embeddings compatibles

Gemini Embedding 2 real · 768 dimensiones en lab/

Mismo modelo, proveedor y dimensión para consultar

El parecido no demuestra veracidad ni suficiencia



PostgreSQL, pgvector y HNSW

vector(768) almacena cada representación

<=> mide distancia coseno: menor es más próximo

HNSW es aproximado; una tabla pequeña puede usar escaneo

```
embedding vector(768) NOT NULL
USING hnsw (embedding vector_cosine_ops)
ORDER BY embedding <=> $1::vector(768) ASC
LIMIT $4
```

Recuperar candidatos y seleccionar contexto

Filtrar por versión y modelo antes de ordenar

top-k = 4 limita la cantidad de candidatos

El umbral decide cuáles pueden llegar al generador

Calibrar y decidir antes de generar

Seis preguntas de validación separadas del test

Corte observado en este ensayo: 0,724767

Sin candidatos aceptados: rechazo sin generador

Contexto, respuesta y citas

Los documentos son datos, no instrucciones

El modelo recibe la pregunta y los fragmentos aceptados

Cada cita debe resolver a un ID suministrado

La misma pregunta sin documentos

Primero: modelo real sin evidencia suministrada

Después: misma pregunta con recuperación

Una abstención es un resultado válido

```
pregunta='¿Con qué algoritmo se cifran los volúmenes en reposo y '\
'qué periodo de enfriamiento exige destruir una CMK?'
bun run lab:real baseline --question "$pregunta" \
  --execute --max-spend-usd 1
```

Reconstruir el índice desde los archivos

10 Markdown en bruto producen 20 fragmentos

Embeddings reales antes de sustituir el índice

Transacción y lectura de vuelta: 20 vectores de 768

```
bun run lab:real rebuild --execute --max-spend-usd 1
bun run lab:real status
```

Consultar con recuperación real

Pregunta → embedding → consulta pgvector

Cifrado: AES-256-GCM · enfriamiento: 72 horas

La traza conserva candidatos, puntuaciones y selección

```
pregunta='¿Con qué algoritmo se cifran los volúmenes en reposo y '\
'qué periodo de enfriamiento exige destruir una CMK?'
bun run lab:real query --question "$pregunta" \
  --execute --max-spend-usd 1 --brief
```

Abrir la fuente y verificar la afirmación

Una cita existente puede seguir siendo insuficiente

Abrir el fragmento y localizar el dato exacto

Comprobar toda la respuesta, no solo el formato

Una pregunta sin respuesta documental

Las licencias de Windows no constan en el corpus

Hay vecinos cercanos, pero no superan el corte

decision: refuse · generationCalled: false

```
pregunta='¿Qué coste mensual tienen las licencias de '\
'Windows Server 2025 en AetherCloud?'
bun run lab:real query --question "$pregunta" \
  --execute --max-spend-usd 1 --brief
```

Filtros de grupo en el asistente del curso

M/J: S10 el 22 de octubre

L/X: S10 el 26 de octubre

Sin grupo, una pregunta de calendario pide aclaración

Evaluar sin ajustar con el test

20 preguntas: 14 respondibles y 6 sin respuesta

Conjunto distinto de las seis de validación

Conservar respuestas, fuentes, puntuaciones y fallos

La práctica que debéis entregar

8 o más documentos ficticios · pgvector 768 + HNSW

Ingesta, consulta, control previo, respuesta y fuentes

Test 14 + 6 ejecutado · README reproducible

Lo que debe poder explicar un RAG

Qué documentos leyó y por qué llegaron al contexto

Qué afirma y qué fuente respalda cada afirmación

Qué hizo cuando no encontró evidencia suficiente

Preguntas y decisiones de diseño

¿Qué cambia si crece el corpus?

¿Dónde falla: ingesta, búsqueda, contexto o generación?

¿Cómo detectar una cita que no respalda la respuesta?

El siguiente paso: CRAG

S11 · martes 27 de octubre · 18:30–20:00

Recuperar, reordenar, valorar y corregir

Mismo problema; más decisiones y un coste que medir

Apéndice: medir recuperación

Hit@k: aparece al menos una evidencia relevante

Recall@k: relevantes recuperados / relevantes esperados

MRR: media de 1 / rango de la primera evidencia relevante