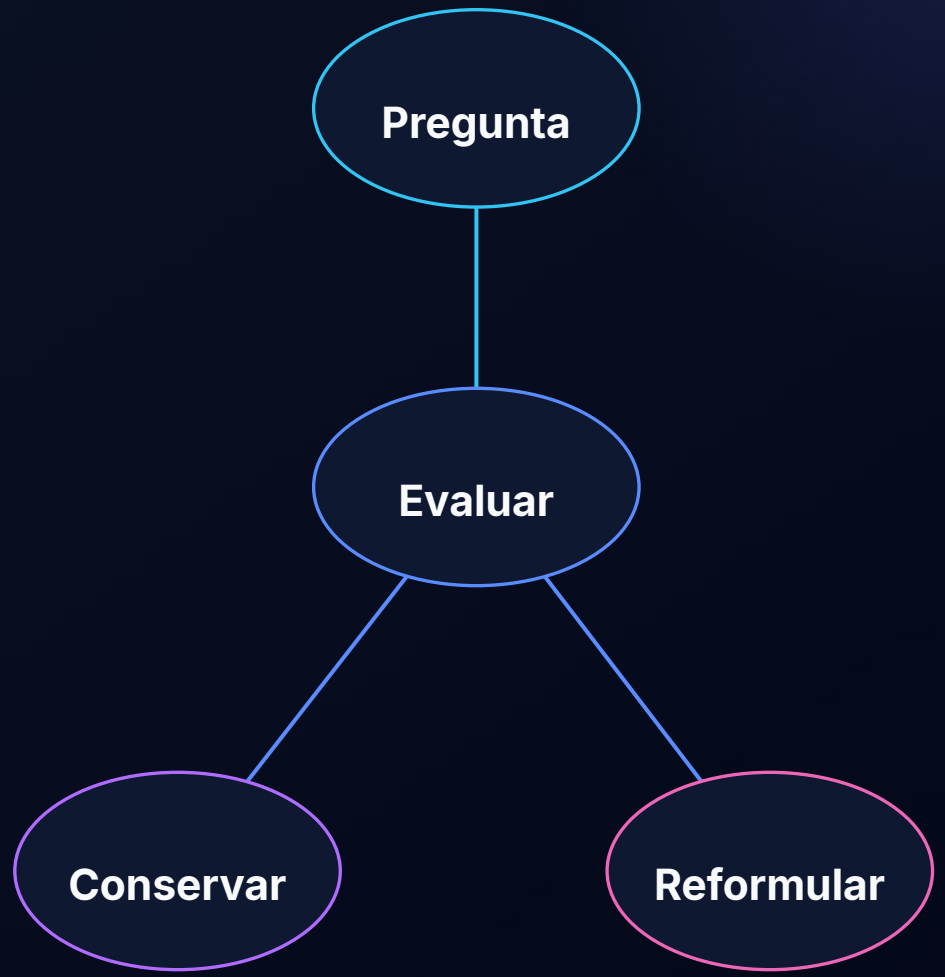
CRAG
El mismo asistente

Corregir la búsqueda, no cambiar de producto.
La aplicación de S10 sigue siendo la base.



27 octubre 2026 · 18:30–20:00

Demo local · TypeScript · Guion

thePower · AI Engineer

José Antonio Nuevo

Antes de empezar

El QR de AI Engineer evalúa nuestra clase S10.

Tu feedback

Escanea el QR. Valora la clase del 22 de octubre.

Hoy veremos

Orden, evidencia, límites y comparación justa.



Evaluación de la clase anterior

Un límite del RAG básico

Una búsqueda no comprueba si falta una parte de la pregunta.

Una pasada

El umbral acepta o descarta. No vuelve a buscar.

Dos temas

Unir S5 y S6 puede quedarse corto a la primera.

Sin victoria

CRAG no garantiza una respuesta mejor.

RAG básico y esta adaptación

Más control también puede añadir latencia y llamadas.

Pieza	RAG básico	Esta adaptación
Búsquedas	Una	Hasta tres
Evidencia	Un umbral	Suficiente o parcial
Generación	Si hay contexto	Solo con evidencia útil

Adaptación de Yan, Gu, Zhu y Ling. No es el artículo.

Estado y consulta de búsqueda

La pregunta original no se sustituye por la reformulación.

Pregunta original

Se conserva durante el turno y llega a la respuesta.

Consulta de búsqueda

Puede cambiar. No borra lo que preguntó el alumno.

```
originalQuestion
currentQuery
// siguen siendo distintas
retrievalCount
reformulationCount
// máximo 3 y 2
// sin checkpointer
// cada turno nace vacío
// packages/rag/src/crag.ts
```

Cada turno nace vacío.

La ordenación sí se aplica

usefullds dice quién entra. El ranking dice el orden.

```
ranking validado
solo ids mostrados

usefulIds dentro de esos ids
máximo 6, sin duplicar
empate: vale la posición
```

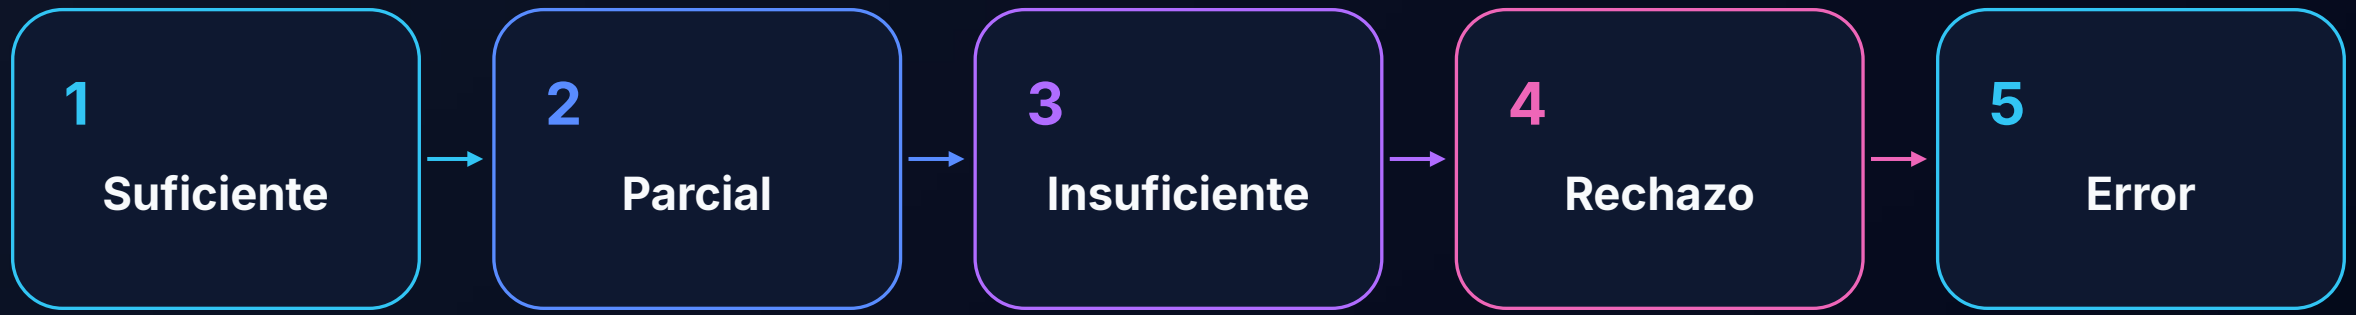


La puntuación no es una probabilidad.

Un guion no mide la calidad del modelo.

Tres juicios y dos salidas

Hace falta texto útil del corpus. Una etiqueta no basta.



Insuficiente no alimenta la respuesta final.

Conservar, unir, no repetir

Lo parcial guarda ids útiles y busca lo que falta.

```
ids previos
ids nuevos
```



El último ranking validado marca el orden.

Descartar y buscar otra vez

Lo rechazado no entra en la respuesta. La pregunta sigue.

Descartar

Se anota el id, el motivo y el intento.

Reformular

Si no avanza o sale vacía, se rechaza.

Otra búsqueda

Cuenta dentro de las tres. No hay una cuarta.

`Cada descarte conserva su intento.`

Límites de un solo turno

El código corta. Una frase del prompt no sustituye el límite.

Búsquedas

Tres, con la primera. Un fallo también cuenta.

Reformulaciones

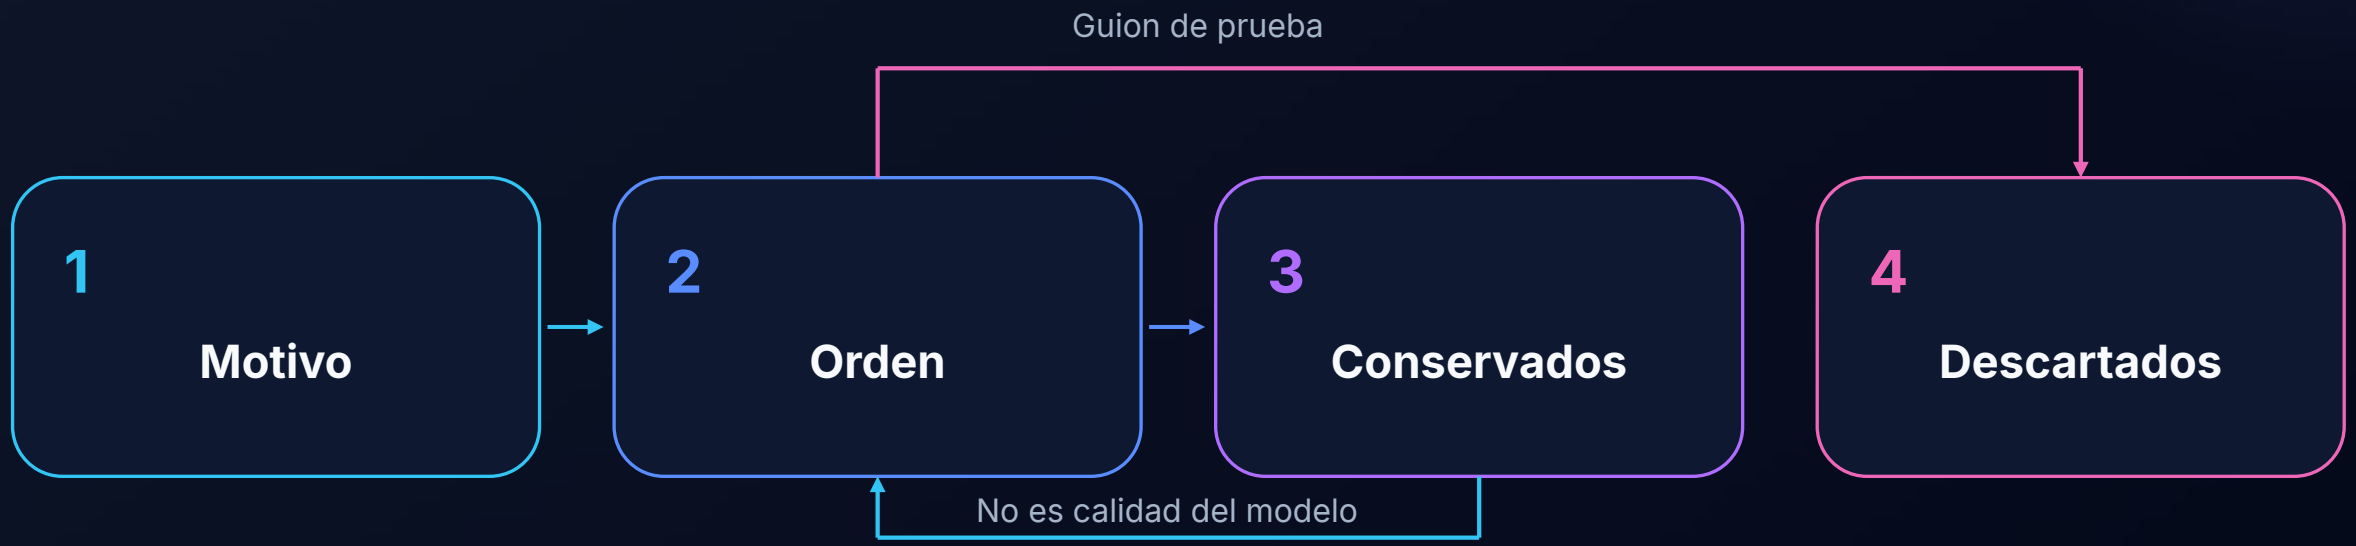
Dos. No hay un reintento escondido.

Plazo

20 s en total. Cada llamada recibe lo que queda.

La traza que ve la clase

Motivo, orden, conservados y descartados. En demo es un guion.



El selector queda quieto mientras la respuesta está en curso.

`fixtures/crag-development-cases.json`

Ejercicio y criterios

Evoluciona el mismo proyecto. Conserva el RAG básico.

Qué mostrar

Orden aplicado, rutas, límites y traza.

Qué conservar

La etapa de una sola búsqueda sigue disponible.

Comparación

Veinte preguntas nuevas. Hoy no hay resultados.

Orientativo del encargo original: 6 a 8 horas.

Consulta · Comparación justa

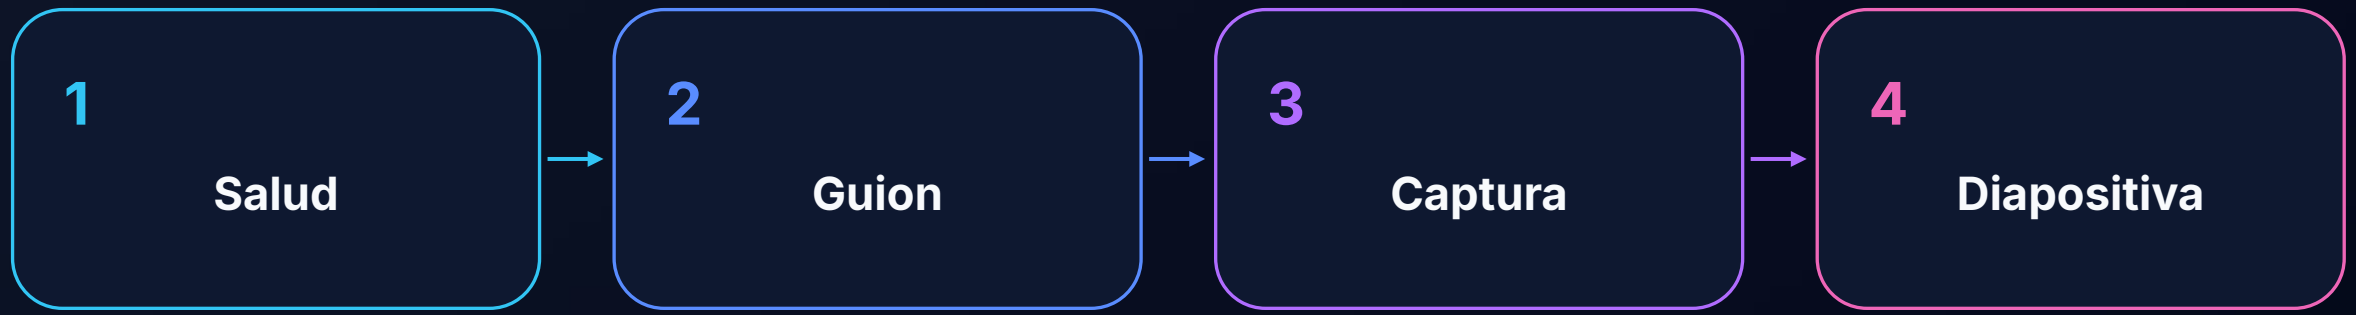
Mismo modelo, corpus y perfil. Sin afinar tras ver el test.

Pieza	Igual en ambos	No hacer
Modelo	El mismo MODEL_ID	Cambiarlo tras el test
Corpus	La misma preparación	Mezclar el fixture
Resultado	Protocolo previsto	Tabla todavía pendiente

Hace falta un presupuesto de lote, aparte.

Consulta · Si el guion falla

Abre la captura del 3 de octubre y vuelve a la diapositiva.



Un guion que acierta no mide CRAG ni el modelo.

`http://localhost:5173/`

Para cerrar

El QR evalúa S10, la clase del 22 de octubre.

Tu feedback

Si queda alguien sin escanear, este es el momento.

Después

La comparación de 20 preguntas espera presupuesto.



Evaluación de la clase anterior