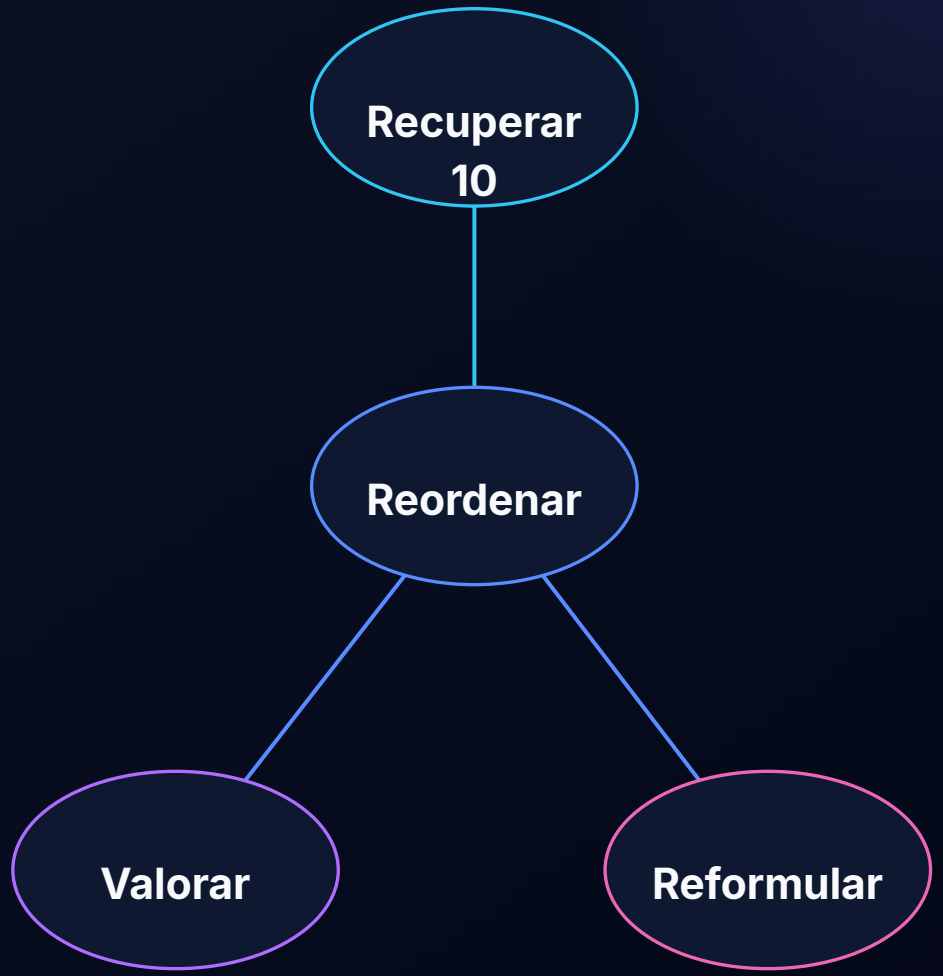
CRAG
El mismo asistente

Recuperar hasta 10, reordenar en [0, 1] y valorar suficiencia.
La etapa de RAG básico se conserva como línea base.

27 octubre 2026 · 18:30–20:00

LangGraph · Rerank [0, 1] · Assess



thePower · AI Engineer

José Antonio Nuevo

Antes de empezar

El QR de AI Engineer evalúa nuestra clase S10.

Tu feedback

Escanea el QR. Valora la clase del 22 de octubre.

Hoy veremos

Recuperar, reordenar, juzgar suficiencia y medir resultados.

Evaluación de la clase anterior

Un límite del RAG básico

Una búsqueda no comprueba si falta una parte de la pregunta.

Una pasada

El umbral acepta o descarta. No vuelve a buscar.

Dos temas

Unir S5 y S6 puede quedarse corto a la primera.

Sin victoria

CRAG no garantiza una respuesta mejor.

RAG básico y esta adaptación

Nodos separados de reordenamiento y valoración con topes estrictos.

Pieza	RAG básico (S10)	CRAG (S11)
Búsquedas	1 (top-4)	Hasta 3 (top-10 + 2 reform.)
Control	Umbral único de similitud	rank [0, 1] + assess suficiencia
Rutas	Responder o rechazar	Suficiente, parcial o insuficiente

Inspirado en Yan, Gu, Zhu y Ling (arXiv:2401.15884).

Estado y consulta de búsqueda

La pregunta original no se sustituye por la reformulación.

Pregunta original

Se conserva durante el turno y llega a la respuesta.

Consulta de búsqueda

Puede cambiar. No borra lo que preguntó el alumno.

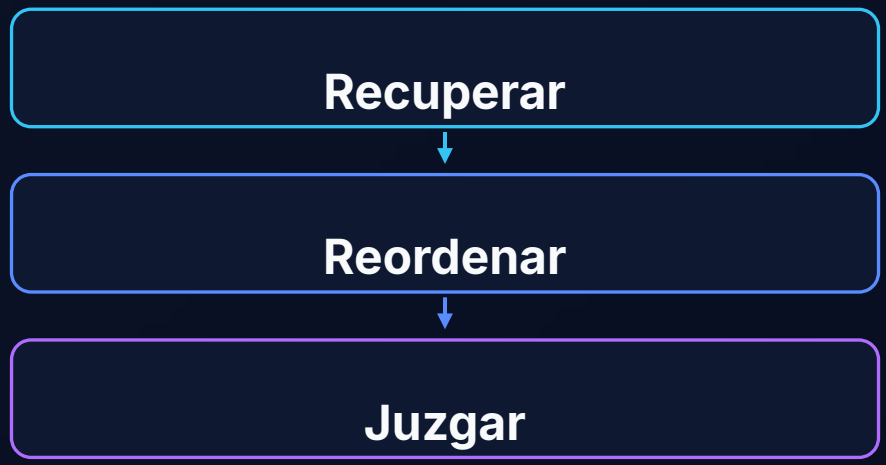
```
originalQuestion
currentQuery
// siguen siendo distintas
retrievalCount
reformulationCount
// máximo 3 y 2
// sin checkpointer
// cada turno nace vacío
// packages/rag/src/crag.ts
```

Cada turno nace vacío.

Recuperar, reordenar y juzgar

Relevancia de un fragmento y cobertura de la pregunta son decisiones distintas.

```
retrieve → hasta 10 candidatos
rank     → score en [0.00, 1.00]
assess   → útil ⩾ 0.50
         → cobertura ⩾ 0.75
// Qwen3-Reranker-0.6B opcional
```

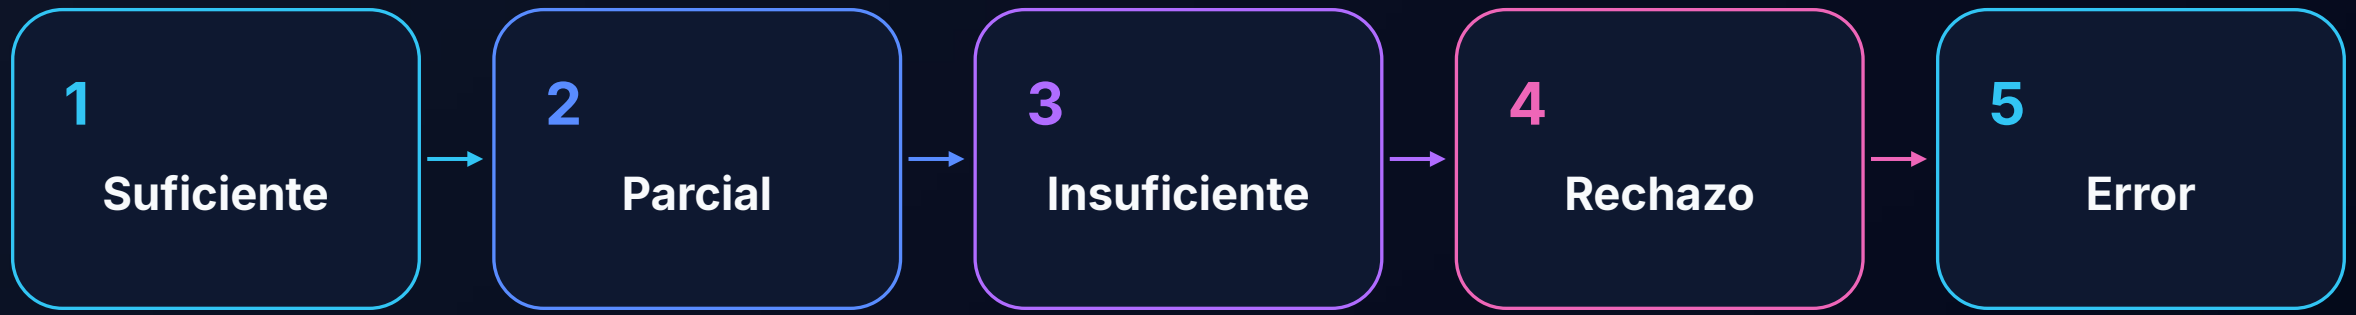


Un fragmento con 0,85 puede cubrir solo media pregunta (partial).

Escala [0, 1] calibrada con validación, nunca con el test.

Umbrales calibrados y rutas del grafo

Corte individual 0,50; cobertura parcial 0,40–0,74; suficiente >= 0,75.



Si tras 3 búsquedas (1 + 2 reformulaciones) no basta, rechaza sin generar.

Ejemplo completo de evidencia parcial

Pasada 1 conserva S5 (0,80); reformula y en la pasada 2 une S6 (0,86).

```
1: S5 (0.80) → partial
2: S6 (0.86) + S5 → answer
```



La cobertura sube de 0,50 (falta S6) a >= 0,75 sin duplicar IDs.

Descartar y buscar otra vez

Lo rechazado no entra en la respuesta. La pregunta sigue.

Descartar

Se anota el id, el motivo y el intento.

Reformular

Si no avanza o sale vacía, se rechaza.

Otra búsqueda

Cuenta dentro de las tres. No hay una cuarta.

`Cada descarte conserva su intento.`

Límites de un solo turno

El código corta. Una frase del prompt no sustituye el límite.

Búsquedas

Tres, con la primera. Un fallo también cuenta.

Reformulaciones

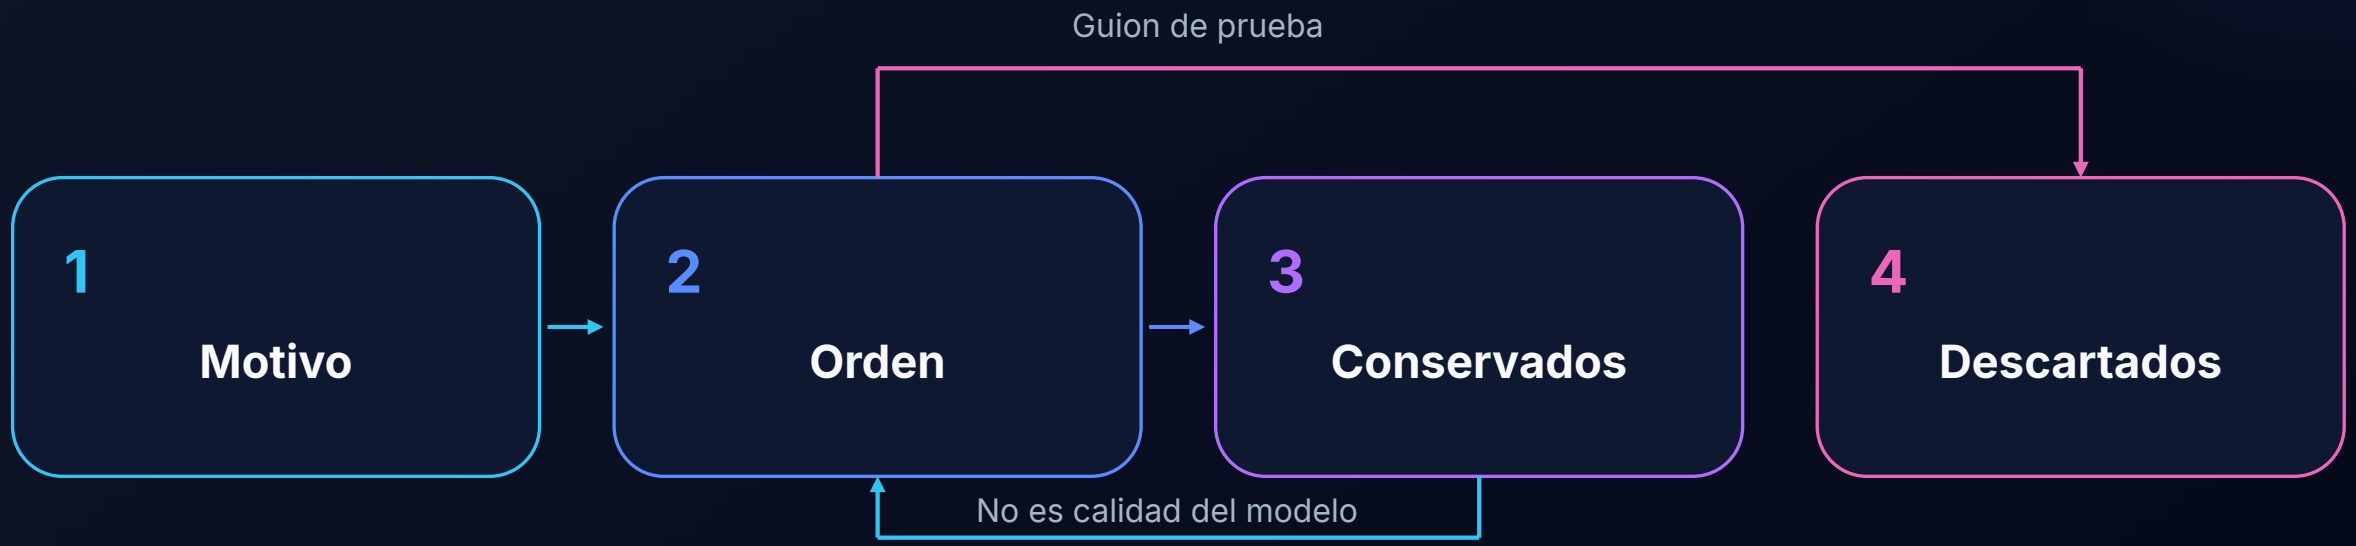
Dos. No hay un reintento escondido.

Plazo

20 s en total. Cada llamada recibe lo que queda.

La traza que ve la clase

Motivo, orden, conservados y descartados. En demo es un guion.



El selector queda quieto mientras la respuesta está en curso.

`fixtures/crag-development-cases.json`

Ejercicio S11 y entrega completa

Reconstruible desde 8+ docs e índice vacío en PostgreSQL/pgvector.

Grafo separado

Recuperar (10), reordenar ([0, 1]), valorar, conservar/descartar y reformular.

Línea base S10

Conservar el RAG básico en el mismo proyecto y trazar las 3 rutas + límite.

Comparación 14+6

Ejecutar 20 preguntas nuevas: X/14, Y/6, recuperaciones medias y latencia.

Dedicación orientativa: 6 a 8 horas. Opcional: Qwen3-Reranker-0.6B.

Consulta · Lectura de métricas y resultados

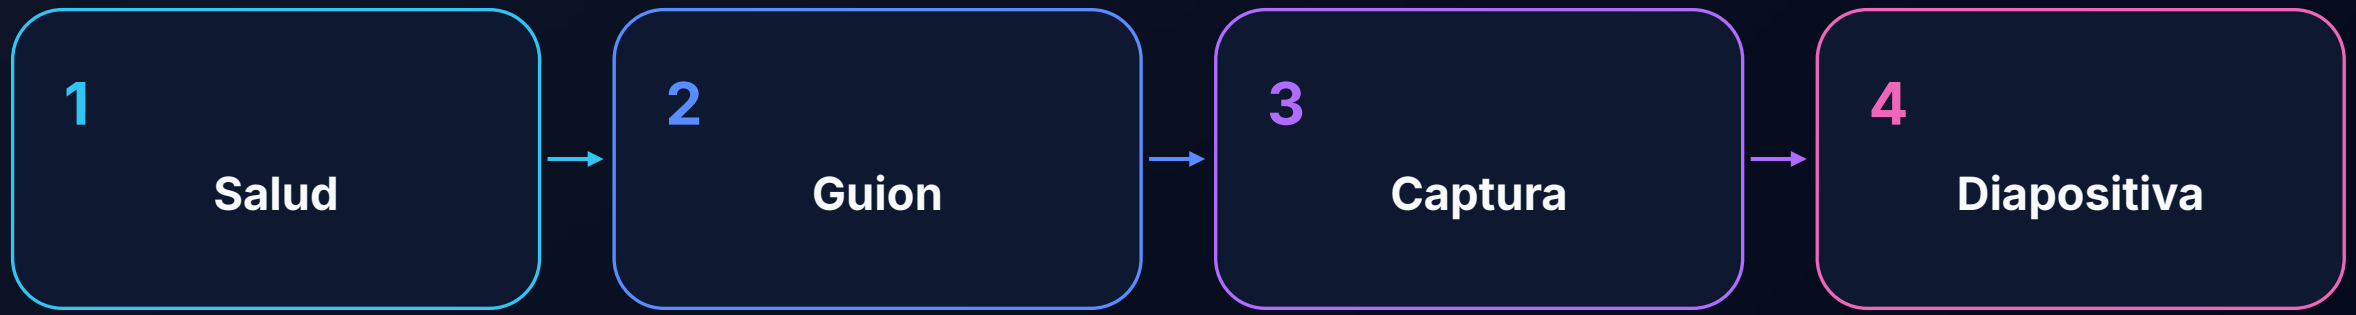
Comparación ejecutada en lab/ (768 d) y lote histórico cloud (1024 d).

Métrica (20 casos)	RAG básico (S10)	CRAG (S11)
Lab pgvector (14 / 6)	16/20 (10/14 · 6/6)	17/20 (11/14 · 6/6)
Histórico cloud (14 / 6)	17/20 (11/14 · 6/6)	18/20 (13/14 · 5/6)
Búsquedas medias / lat.	1,00 (lab) · 0,95 (1,19 s)	1,80 (lab) · 1,55 (4,30 s)

CRAG recupera preguntas compuestas a cambio de más búsquedas y latencia.

Consulta · Si el guion falla

Abre la captura del 3 de octubre y vuelve a la diapositiva.



Un guion que acierta no mide CRAG ni el modelo.

`http://localhost:5173/`

Para cerrar

El QR evalúa S10, la clase del 22 de octubre.

Tu feedback

Si queda alguien sin escanear, este es el momento.

Después

Comparación ejecutada en lab/ y referencia actual congelada.



Evaluación de la clase anterior