thePower

S12 · AI ENGINEER

Deep Research y multimodal

Imagen y audio en un agente que investiga con fuentes

José Antonio Nuevo

Jueves 29 de octubre de 2026 · 18:30–20:00 · Madrid

Imagen + audio + memoria + herramientas + fuentes

Evaluación de la clase anterior

S11 · RAG avanzado y CRAG · martes 27 de octubre



Encuesta AI Engineer

Escanea el QR y valora el ritmo, las explicaciones y la práctica

Mientras respondes

Piensa en una pregunta que requiera información fuera del corpus

Objetivo de la sesión

Un grafo de chatbot con memoria, herramientas e investigación

Entrada	Una imagen y un audio aportan información complementaria
Decisión	El agente elige respuesta directa, herramienta o investigación
Salida	Un informe distingue lo comprobado de lo que falta
Continuidad	La conversación conserva contexto y puede producir voz

60 minutos de conceptos y 30 de aplicación, evidencia y ejercicio

Respuesta directa, RAG, CRAG e investigación

Recorrido	Información que utiliza	Cuándo encaja
Respuesta directa	La petición y el contexto disponible	La tarea no necesita nuevas fuentes
RAG	Documentos de un corpus	La respuesta está en la documentación propia
CRAG	Corpus y evaluación de lo recuperado	La primera recuperación es insuficiente
Investigación	Subpreguntas y fuentes que se consultan	Hay que reunir información que falta

La política de búsqueda y sus límites forman parte del diseño

Multimodalidad

El sistema trabaja con más de un tipo de información

Texto	Pregunta, instrucciones y contexto de la conversación
Imagen	Contenido visual, texto visible y relaciones espaciales
Audio	Petición hablada que podemos transcribir
Voz de salida	Lectura de una respuesta seleccionada

Cada modalidad conserva su origen y sus límites

Lectura de imagen y OCR

La captura aporta una observación que todavía debemos interpretar



Texto observado	El sistema espera 1024 dimensiones y recibe 768
Pregunta abierta	¿Qué configuración genera cada dimensión?
Comprobación	Revisar el modelo y el índice antes de proponer cambios

Leer el error no identifica por sí solo la causa

Procesamiento de archivos

La extensión del nombre no basta para aceptar una entrada

Formato	Comprobar el contenido y que se pueda decodificar
Tamaño	Limitar bytes, dimensiones y duración antes de procesar
Almacenamiento	Guardar el archivo por separado y conservar una referencia
Error	Explicar el rechazo sin fingir una lectura correcta

En esta demo: PNG/JPEG y audio WAV de hasta 30 segundos

Audio a texto

La transcripción convierte el audio en una petición que podemos revisar

Entrada	Una nota de voz breve y comprensible
Transcripción	Texto con el que trabajará el agente
Revisión	Nombres, cifras y términos técnicos pueden fallar
Trazabilidad	Conservar el original y la transcripción utilizada

El ensayo real transcribió «RAG» como «Rack»

Fusión de entradas

Cada entrada aporta una parte distinta de la pregunta

La imagen	El índice espera 1024 y recibe 768
El audio	El error apareció después de cambiar embeddings
La intención	Investigar el significado y qué configuración revisar
La pregunta	Qué relación deben tener modelo e índice y cómo comprobarla

Una contradicción o una entrada que no cabe exige aclaración

Herramientas y elección de ruta

Una herramienta es una función con un contrato y un alcance

Consulta directa	La respuesta necesita solo el contexto disponible
Herramienta	Leer una ficha estructurada con argumentos validados
Investigación	Buscar y leer fuentes para resolver una laguna
Ejemplo de aula	get_course_session consulta la ficha S12 del grupo M/J

El programa valida permisos y argumentos antes de ejecutar

Memoria y conversaciones aisladas

La memoria permite entender «ese índice» en el siguiente turno

Conversación	Un identificador relaciona los turnos del mismo hilo
Checkpoint	Conserva el estado necesario para continuar el grafo
Archivos	Referencias y observaciones, con los bytes fuera del estado
Aislamiento	Otro hilo o propietario no hereda esos datos

La memoria aporta contexto y las fuentes aportan evidencia

Deep Research

Una investigación reúne y revisa evidencia antes de redactar

Planificar	Dividir la pregunta y decidir qué falta comprobar
Reunir	Consultar corpus, herramientas y páginas relevantes
Evaluar	Comprobar qué subpreguntas siguen sin respuesta
Cerrar	Redactar con fuentes o explicar los límites

Otra ronda solo se justifica si puede resolver una laguna

Búsqueda, lectura y evidencia

Pieza	Qué aporta	Qué hay que comprobar
Resultado del buscador	Una página candidata	Dominio, tema y versión
Página leída	Contenido y contexto	Que responda a la pregunta
Extracto	Un tramo que respalda una afirmación	Texto, cifras y procedencia
Adjunto del usuario	Una observación del caso	Su origen y sus limitaciones

Una URL citada tiene que respaldar la afirmación concreta

Verificación e informes parciales

Un trabajo puede terminar correctamente y dejar preguntas abiertas

Cobertura	Qué subpreguntas tienen evidencia suficiente
Afirmaciones	Qué fuente respalda cada frase factual
Resultado parcial	Qué sabemos y qué falta comprobar
Límite	Una cita literal tampoco garantiza que la fuente sea correcta

Ejecución terminada e informe completo son estados distintos

Ejecución asíncrona

El cliente inicia un trabajo y consulta su resultado después

Crear	Enviar la petición y obtener un identificador
Conservar	Guardar ese identificador y el contexto autorizado
Consultar	Leer el estado del mismo trabajo con una espera acotada
Recuperar	Volver al resultado sin crear otra investigación

Cerrar la pestaña no tiene por qué detener el trabajo

Gemini Deep Research e Interactions API

El enunciado propone un agente gestionado en segundo plano

Inicio	interactions.create con agent y background=True
Identidad	Guardar interaction.id antes de consultar
Seguimiento	interactions.get del mismo ID hasta completar o fallar
Espera agotada	Conservar el ID y explicar que el trabajo puede seguir

La demo de 3-rag usa un grafo propio y otro ID de trabajo

Límites de tiempo y coste

Los límites se comprueban antes de iniciar otra operación

Tiempo	120 segundos para el trabajo de investigación de esta app
Exploración	Hasta 3 subpreguntas, 2 rondas, 4 búsquedas y 6 lecturas
Modelos	Hasta 5 llamadas de investigación, con medios contados aparte
Dinero	Presupuesto separado y consumo desconocido visible

Estos son límites del laboratorio, no garantías de rendimiento

Texto a voz

La locución parte de un texto que ya hemos seleccionado

Selección	Hasta 3 frases y 600 caracteres en esta app
Procedencia	Frases verificadas y avisos claros sobre el resultado
Generación	Un servicio TTS produce el archivo de audio
Reproducción	El usuario pulsa reproducir y puede volver a escuchar

Un fallo de voz conserva el informe escrito

Errores y respuestas útiles

Situación	Respuesta del sistema
Archivo inválido	Rechazo con una explicación del formato
Entradas contradictorias	Aclaración antes de investigar
Fuentes insuficientes	Informe parcial o rechazo
Espera agotada	Estado e ID conservados para seguimiento
Fallo de TTS	Informe disponible y aviso de voz fallida

Un error visible es preferible a una sustitución silenciosa

El grafo del ejercicio

Cada nodo transforma una entrada y deja un resultado comprobable

Admisión y percepción	Archivo válido, observación visual y transcripción
Fusión y ruta	Pregunta completa y decisión de capacidad
Investigación y memoria	Fuentes, estado del trabajo y contexto por hilo
Verificación y salida	Informe, puntos abiertos y voz opcional

Las pruebas deben observar cada transformación

La aplicación que ya tenemos

Capacidad	Implementación de la demo
Investigación	Grafo propio con LangGraph y fuentes externas
Texto y visión	Proveedor configurado · ensayo con Claude Haiku 5.5
Búsqueda y lectura	Ensayo con Tavily y páginas de documentación
Audio y voz	Whisper para STT y Aura-2 es para TTS
Persistencia	D1, R2 y Workflows en Cloudflare

Gemini es la referencia del enunciado y la app muestra otra implementación

Demostración del caso completo

La misma captura y el mismo audio durante todo el recorrido

1 · Entradas	Adjuntar la captura y la nota de voz
2 · Proceso	Revisar observación, transcripción, plan y fuentes
3 · Resultado	Leer el informe y el texto de voz
4 · Continuidad	Recargar, preguntar «ese índice» y abrir otro hilo

Demo principal local sin gasto · ensayo real guardado a continuación

Lo observado en el ensayo real

Ejecuciones guardadas del 11 de octubre de 2026

48,712 s

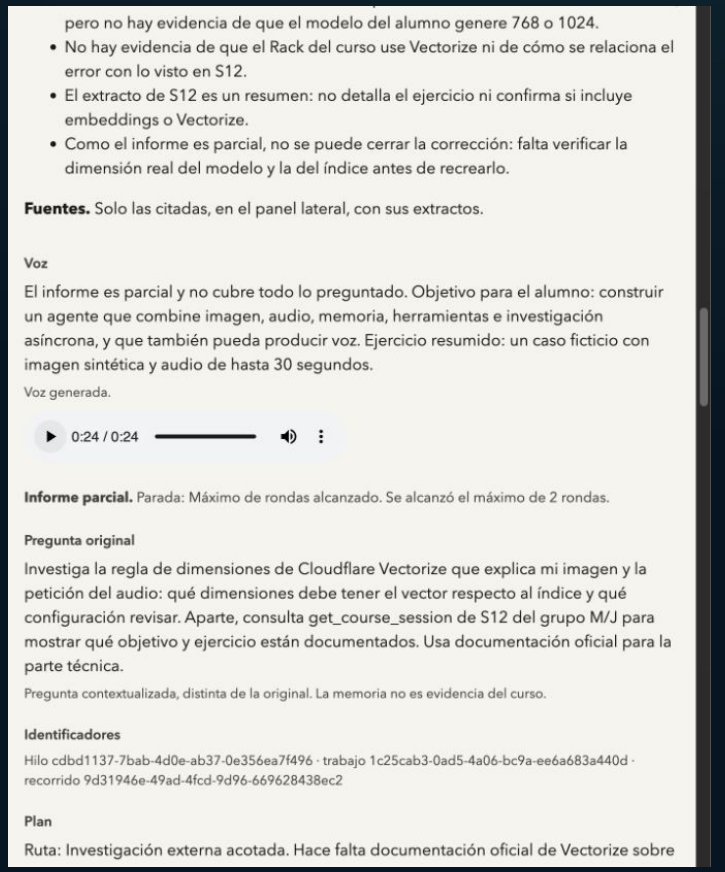
Informe completo con 7 afirmaciones verificadas

45,158 s

Informe parcial con 8 afirmaciones verificadas

24,504 s

Audio real recuperado y reproducido tras la recarga


pero no hay evidencia de que el modelo del alumno genere 768 o 1024.

- No hay evidencia de que el Rack del curso use Vectorize ni de cómo se relaciona el error con lo visto en S12.
- El extracto de S12 es un resumen: no detalla el ejercicio ni confirma si incluye embeddings o Vectorize.
- Como el informe es parcial, no se puede cerrar la corrección: falta verificar la dimensión real del modelo y la del índice antes de recrearlo.

Fuentes. Solo las citadas, en el panel lateral, con sus extractos.

Voz

El informe es parcial y no cubre todo lo preguntado. Objetivo para el alumno: construir un agente que combine imagen, audio, memoria, herramientas e investigación asíncrona, y que también pueda producir voz. Ejercicio resumido: un caso ficticio con imagen sintética y audio de hasta 30 segundos.

Voz generada.

0:24 / 0:24

Informe parcial. Parada: Máximo de rondas alcanzado. Se alcanzó el máximo de 2 rondas.

Pregunta original

Investiga la regla de dimensiones de Cloudflare Vectorize que explica mi imagen y la petición del audio: qué dimensiones debe tener el vector respecto al índice y qué configuración revisar. Aparte, consulta get_course_session de S12 del grupo M/J para mostrar qué objetivo y ejercicio están documentados. Usa documentación oficial para la parte técnica.

Pregunta contextualizada, distinta de la original. La memoria no es evidencia del curso.

Identificadores

Hilo cdbd1137-7bab-4d0e-ab37-0e356ea7f496 · trabajo 1c25cab3-0ad5-4a06-bc9a-ee6a683a440d · recorrido 9d31946e-49ad-4fcd-9d96-669628438ec2

Plan

Ruta: Investigación externa acotada. Hace falta documentación oficial de Vectorize sobre

Son ejemplos del recorrido y no una tasa general de precisión

Ejercicio y preguntas finales

Un caso ficticio y una evidencia clara por capacidad

Multimodalidad	Imagen y audio influyen en la respuesta
Agente	Memoria aislada y herramienta propia de solo lectura
Investigación	Un trabajo real, su ID, sus fuentes y sus límites
Entrega	Código, entradas, audio de salida, pruebas y limitaciones

Una simulación sirve para ensayar los fallos y debe identificarse