thePower

S12 · AI ENGINEER

Deep Research y multimodal

Imagen y audio en un agente que investiga con fuentes

José Antonio Nuevo

Jueves 29 de octubre de 2026 · 18:30–20:00 · Madrid

Imagen + audio + memoria + herramientas + fuentes

Evaluación de la clase anterior

S11 · RAG avanzado y CRAG · martes 27 de octubre



Encuesta AI Engineer

Escanea el QR y valora el ritmo, las explicaciones y la práctica

Mientras respondes

Piensa en una pregunta que requiera información fuera del corpus

Objetivo de la sesión

Un grafo de chatbot con memoria, herramientas e investigación

Entrada	Una imagen y un audio aportan información complementaria
Decisión	El agente elige respuesta directa, herramienta o investigación
Salida	Un informe distingue lo comprobado de lo que falta
Continuidad	La conversación conserva contexto y puede producir voz

60 minutos de conceptos y 30 de aplicación, evidencia y ejercicio

Respuesta directa, RAG, CRAG e investigación

Recorrido	Información que utiliza	Cuándo encaja
Respuesta directa	La petición y el contexto disponible	La tarea no necesita nuevas fuentes
RAG	Documentos de un corpus	La respuesta está en la documentación propia
CRAG	Corpus y evaluación de lo recuperado	La primera recuperación es insuficiente
Investigación	Subpreguntas y fuentes que se consultan	Hay que reunir información que falta

La política de búsqueda y sus límites forman parte del diseño

Multimodalidad

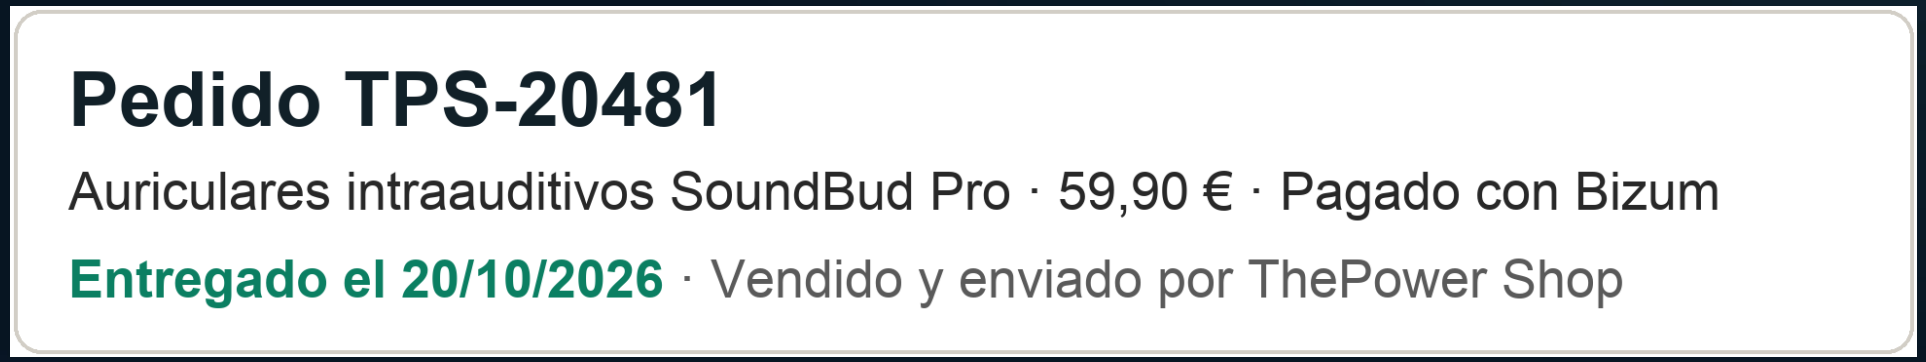
El sistema trabaja con más de un tipo de información

Texto	Pregunta, instrucciones y contexto de la conversación
Imagen	Contenido visual, texto visible y relaciones espaciales
Audio	Petición hablada que podemos transcribir
Voz de salida	Lectura de una respuesta seleccionada

Cada modalidad conserva su origen y sus límites

Lectura de imagen y OCR

La foto aporta una observación que todavía debemos interpretar



Texto observado	Pedido TPS-20481: auriculares, Bizum, entregado el 20/10
Pregunta abierta	¿Qué le pasa al pedido y qué quiere el cliente?
Comprobación	Confirmar el pedido con la herramienta antes de responder

Leer la foto no explica por sí sola el problema

Procesamiento de archivos

La extensión del nombre no basta para aceptar una entrada

Formato	Comprobar el contenido y que se pueda decodificar
Tamaño	Limitar bytes, dimensiones y duración antes de procesar
Almacenamiento	Guardar el archivo por separado y conservar una referencia
Error	Explicar el rechazo sin fingir una lectura correcta

En esta demo: PNG/JPEG y audio WAV de hasta 30 segundos

Audio a texto

La transcripción convierte el audio en una petición que podemos revisar

Entrada	Una nota de voz breve y comprensible
Transcripción	Texto con el que trabajará el agente
Revisión	Nombres, cifras y términos técnicos pueden fallar
Trazabilidad	Conservar el original y la transcripción utilizada

Un número o una marca mal transcritos cambian la pregunta

Fusión de entradas

Cada entrada aporta una parte distinta de la pregunta

La imagen	Pedido TPS-20481: auriculares pagados con Bizum
El audio	Los abrió y el auricular derecho no suena
La intención	Saber si puede devolverlos y cuándo recibe el dinero
La pregunta	Qué dicen la política de la tienda y la normativa para este pedido

Una contradicción o una entrada que no cabe exige aclaración

Herramientas y elección de ruta

Una herramienta es una función con un contrato y un alcance

Consulta directa	La respuesta necesita solo el contexto disponible
Herramienta	Leer un dato estructurado con argumentos validados
Investigación	Buscar y leer fuentes para resolver una laguna
Ejemplo de aula	get_order lee el pedido TPS-20481 de la cuenta de la conversación

El programa valida permisos y argumentos antes de ejecutar

Memoria y conversaciones aisladas

La memoria permite entender «ese pedido» en el siguiente turno

Conversación	Un identificador relaciona los turnos del mismo hilo
Checkpoint	Conserva el estado necesario para continuar el grafo
Archivos	Referencias y observaciones, con los bytes fuera del estado
Aislamiento	Otro hilo o propietario no hereda esos datos

La memoria aporta contexto y las fuentes aportan evidencia

Deep Research

Una investigación reúne y revisa evidencia antes de redactar

Planificar	Dividir la pregunta y decidir qué falta comprobar
Reunir	Consultar corpus, herramientas y páginas relevantes
Evaluar	Comprobar qué subpreguntas siguen sin respuesta
Cerrar	Redactar con fuentes o explicar los límites

Otra ronda solo se justifica si puede resolver una laguna

Búsqueda, lectura y evidencia

Pieza	Qué aporta	Qué hay que comprobar
Resultado del buscador	Una página candidata	Dominio, tema y versión
Página leída	Contenido y contexto	Que responda a la pregunta
Extracto	Un tramo que respalda una afirmación	Texto, cifras y procedencia
Adjunto del usuario	Una observación del caso	Su origen y sus limitaciones

Una URL citada tiene que respaldar la afirmación concreta

Verificación e informes parciales

Un trabajo puede terminar correctamente y dejar preguntas abiertas

Cobertura	Qué subpreguntas tienen evidencia suficiente
Afirmaciones	Qué fuente respalda cada frase factual
Resultado parcial	Qué sabemos y qué falta comprobar
Límite	Una cita literal tampoco garantiza que la fuente sea correcta

Ejecución terminada e informe completo son estados distintos

Ejecución asíncrona

El cliente inicia un trabajo y consulta su resultado después

Crear	Enviar la petición y obtener un identificador
Conservar	Guardar ese identificador y el contexto autorizado
Consultar	Leer el estado del mismo trabajo con una espera acotada
Recuperar	Volver al resultado sin crear otra investigación

Cerrar la pestaña no tiene por qué detener el trabajo

Gemini Deep Research e Interactions API

El enunciado propone un agente gestionado en segundo plano

Inicio	interactions.create con agent y background=True
Identidad	Guardar interaction.id antes de consultar
Seguimiento	interactions.get del mismo ID hasta completar o fallar
Espera agotada	Conservar el ID y explicar que el trabajo puede seguir

La demo de 3-rag usa un grafo propio y otro ID de trabajo

Límites de tiempo y coste

Los límites se comprueban antes de iniciar otra operación

Tiempo	120 segundos para el trabajo de investigación de esta app
Exploración	Hasta 3 subpreguntas, 2 rondas, 4 búsquedas y 6 lecturas
Modelos	Hasta 5 llamadas de investigación, con medios contados aparte
Dinero	Presupuesto separado y consumo desconocido visible

Estos son límites del laboratorio, no garantías de rendimiento

Texto a voz

La locución parte de un texto que ya hemos seleccionado

Selección	Hasta 3 frases y 600 caracteres en esta app
Procedencia	Frases verificadas y avisos claros sobre el resultado
Generación	Un servicio TTS produce el archivo de audio
Reproducción	El usuario pulsa reproducir y puede volver a escuchar

Un fallo de voz conserva el informe escrito

Errores y respuestas útiles

Situación	Respuesta del sistema
Archivo inválido	Rechazo con una explicación del formato
Entradas contradictorias	Aclaración antes de investigar
Fuentes insuficientes	Informe parcial o rechazo
Espera agotada	Estado e ID conservados para seguimiento
Fallo de TTS	Informe disponible y aviso de voz fallida

Un error visible es preferible a una sustitución silenciosa

El grafo del ejercicio

Cada nodo transforma una entrada y deja un resultado comprobable

Admisión y percepción	Archivo válido, observación visual y transcripción
Fusión y ruta	Pregunta completa y decisión de capacidad
Investigación y memoria	Fuentes, estado del trabajo y contexto por hilo
Verificación y salida	Informe, puntos abiertos y voz opcional

Las pruebas deben observar cada transformación

La aplicación que ya tenemos

Capacidad	Implementación de la demo
Investigación	Grafo propio con LangGraph: políticas, pedidos y web
Texto y visión	Proveedor configurado · Claude Haiku 5.5 publicado
Búsqueda y lectura	Tavily y páginas oficiales de consumo (UE y BOE)
Audio y voz	Whisper para STT y Aura-2 es para TTS
Persistencia	D1, R2 y Workflows en Cloudflare

Gemini es la referencia del enunciado y la app muestra otra implementación

Demostración del caso completo

La misma foto y la misma nota de voz durante todo el recorrido

1 · Entradas	Adjuntar la foto del pedido y la nota de voz
2 · Proceso	Revisar observación, transcripción, plan y fuentes
3 · Resultado	Leer el informe y el texto de voz
4 · Continuidad	Recargar, preguntar «¿y ese pedido?» y abrir otro hilo

Demo principal local sin gasto · a continuación, qué comprobar en una ejecución real

Qué comprobar en una ejecución real

La demo local enseña el recorrido; un trabajo real se comprueba así

1 ID

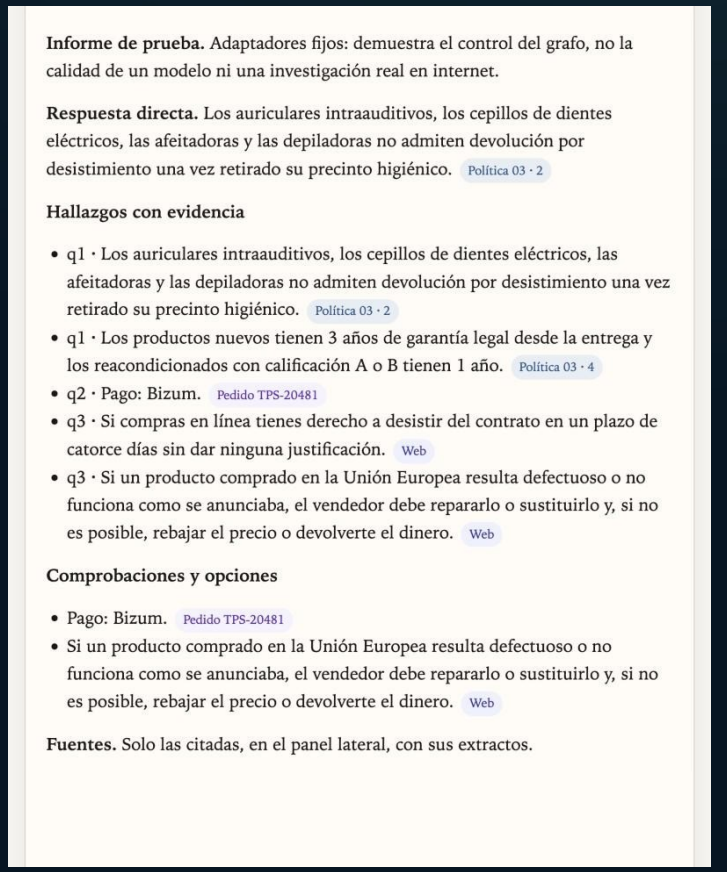
El mismo trabajo al recargar, sin operaciones de pago nuevas

3 vías

Políticas, get_order y normativa, cada una con su fuente

0,25 USD

Tope por trabajo; lo desconocido queda retenido



Informe de prueba. Adaptadores fijos: demuestra el control del grafo, no la calidad de un modelo ni una investigación real en internet.

Respuesta directa. Los auriculares intraauditivos, los cepillos de dientes eléctricos, las afeitadoras y las depiladoras no admiten devolución por desistimiento una vez retirado su precinto higiénico. Política 03 · 2

Hallazgos con evidencia

- q1 · Los auriculares intraauditivos, los cepillos de dientes eléctricos, las afeitadoras y las depiladoras no admiten devolución por desistimiento una vez retirado su precinto higiénico. Política 03 · 2
- q1 · Los productos nuevos tienen 3 años de garantía legal desde la entrega y los reacondicionados con calificación A o B tienen 1 año. Política 03 · 4
- q2 · Pago: Bizum. Pedido TPS-20481
- q3 · Si compras en línea tienes derecho a desistir del contrato en un plazo de catorce días sin dar ninguna justificación. Web
- q3 · Si un producto comprado en la Unión Europea resulta defectuoso o no funciona como se anunciaba, el vendedor debe repararlo o sustituirlo y, si no es posible, rebajar el precio o devolverte el dinero. Web

Comprobaciones y opciones

- Pago: Bizum. Pedido TPS-20481
- Si un producto comprado en la Unión Europea resulta defectuoso o no funciona como se anunciaba, el vendedor debe repararlo o sustituirlo y, si no es posible, rebajar el precio o devolverte el dinero. Web

Fuentes. Solo las citadas, en el panel lateral, con sus extractos.

Son comprobaciones del recorrido, no una tasa general de precisión

Ejercicio y preguntas finales

Un caso ficticio y una evidencia clara por capacidad

Multimodalidad	Imagen y audio influyen en la respuesta
Agente	Memoria aislada y herramienta propia de solo lectura
Investigación	Un trabajo real, su ID, sus fuentes y sus límites
Entrega	Código, entradas, audio de salida, pruebas y limitaciones

Una simulación sirve para ensayar los fallos y debe identificarse